

# MODELOS AUTORREGRESSIVOS , INTERGRADOS E DE MÉDIAS MÓVEIS - ARIMA



Quando uma série temporal não é estacionária, devemos deixá-la estacionária para realizarmos nossas estimações.

De uma maneira geral, podemos dividir nossa série temporal em três partes:

$$Y_t = \text{tendência} + \text{componente estacionário} + \text{ruído}$$




Para detectar componentes não estacionários e tendência em um série podemos utilizar:

Análise gráfica: padrões como a inclinação nos dados e se sua variação constante no tempo ou não.



# Função de Autocorrelação - FAC

Num processo não estacionário a correlação, expressa na FAC, demora a cair.




Aplicando os testes estatísticos de raiz unitária, lembrando que o teste de raiz unitária, como o de Dickey-Fuller, Philips-Perron, KPSS, ERS, NG e Perron, dentre outros

*Para o teste de Dick Fuller :*

$H_0$ :tem raiz unitária e não é estacionária

$H_A$ :não tem raiz unitária e é estacionária



## Método das Diferenças – Ordem de Integração (d)

O modelo ARIMA (p, d, q) é adequado para a previsão de séries temporais cujo processo estocástico não é estacionário.

Uma forma de deixar as séries estacionárias é diferenciando-as, efetuando suas diferenças.

O número necessário de diferenças para tornar uma série estacionária é denominado ordem de integração (d).

$$\Delta y_t = y_t - y_{t-1} : \text{ordem } d = 1$$
$$\Delta y_t = (y_t - y_{t-1}) - (y_{t-1} - y_{t-2}) : \text{ordem } d = 2$$

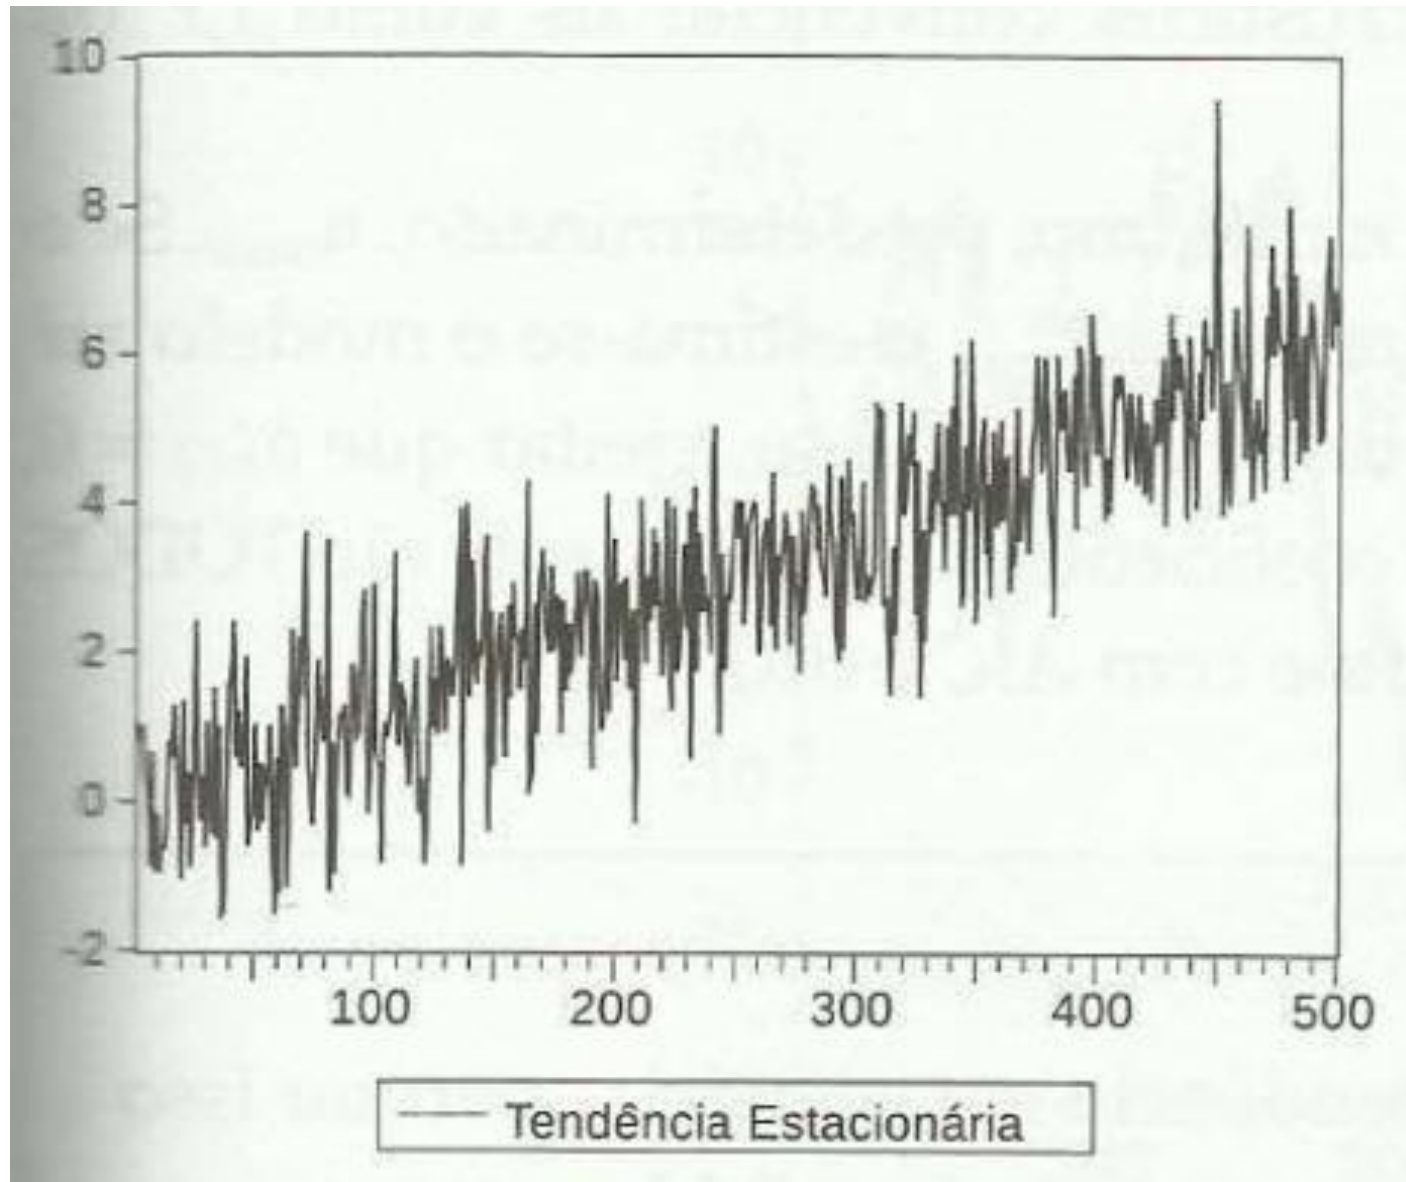
## Tendência Estacionária e Estocástica

Considere o modelo abaixo:

$$y_t = y_0 + \delta_t + \varphi(L)_t \varepsilon_t$$

Esse modelo é chamado de tendência estacionária.

Flutua em torno de uma tendência determinística, sem jamais se distanciar de tal tendência.



## Tendência Estocástica Pura ou Passeio Aleatório

Um passeio aleatório ou tendência estocástica pura é um processo puramente não estacionário com raiz unitária.

$$y_t = 1y_{t-1} + \varepsilon_t$$



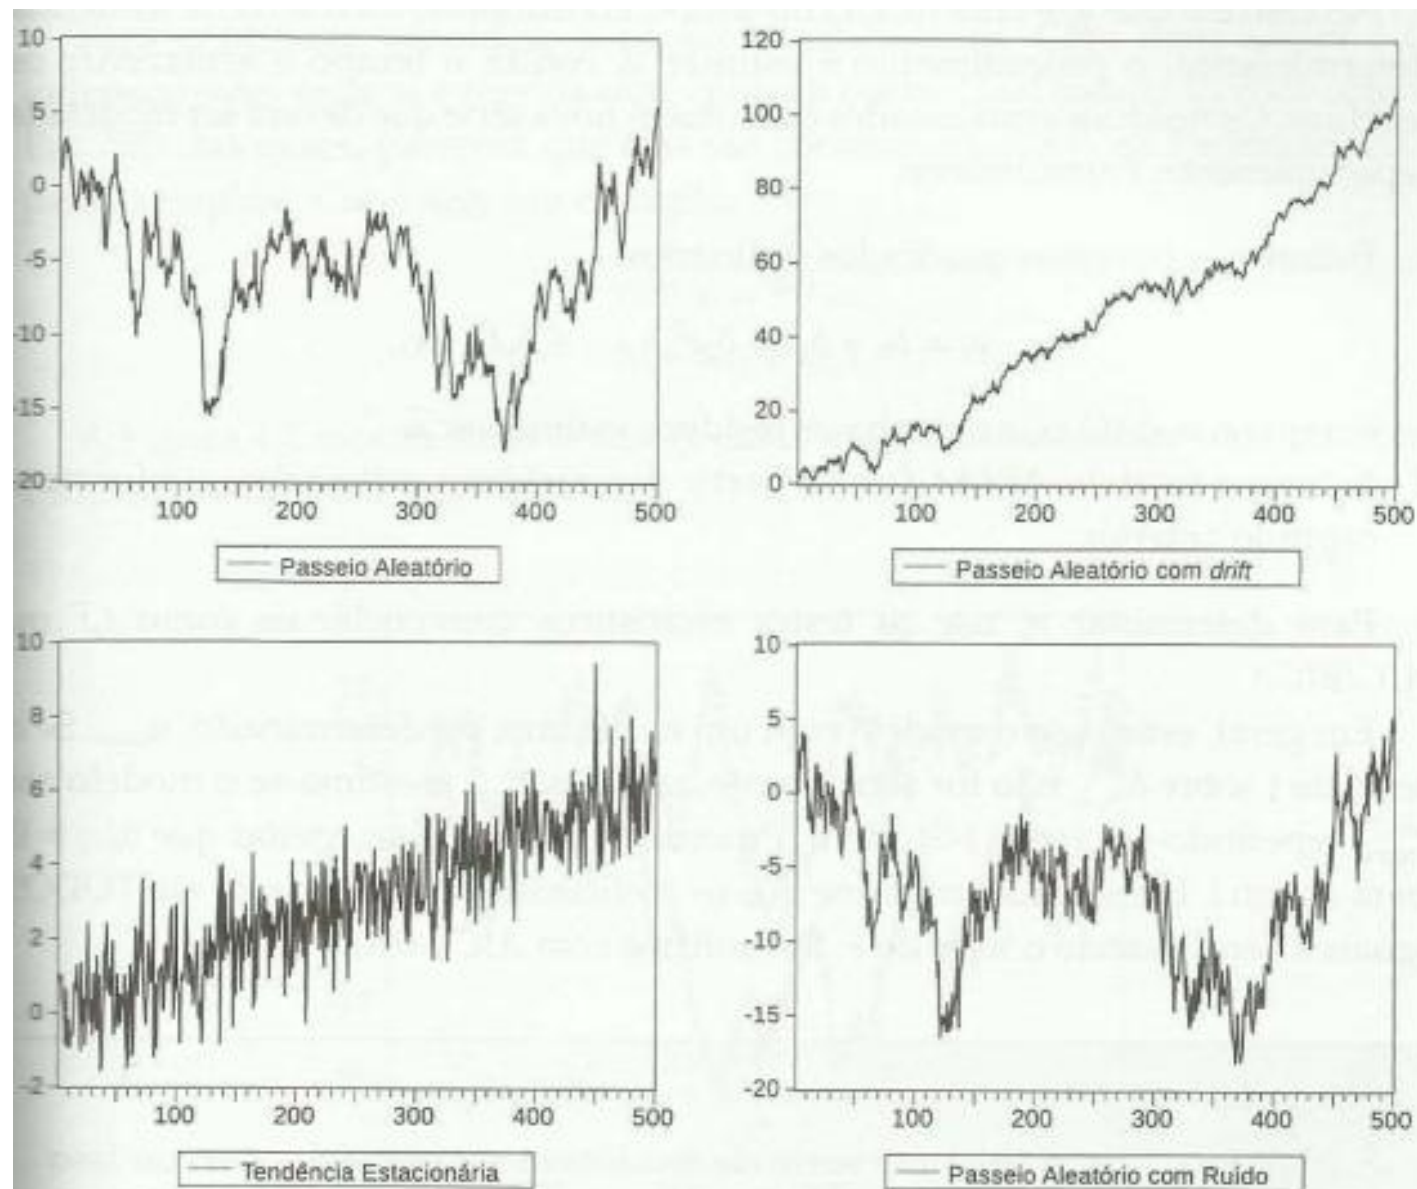


Figura 4.1 Séries temporais com tendência.

## Removendo a Tendência

Podemos tornar uma série estacionária subtraindo sua tendência determinística.

No modelo com tendência estocástica basta diferenciar a série para estacionarizá-la, inclusive quando houver tendência determinística.

Se a série for integrada de ordem  $d$ , toma-se a  $d$ -ésima diferença para estacionarizar a série.

No caso da tendência determinística, o procedimento é estimar  $y_t$  em função do tempo e armazenar os resíduos.

Esses resíduos serão a nova série de dados que deverá ser modelada, expurgada a tendência.

```
library("urca")  
library(readxl)  
library(pwt8)
```

```
data("pwt8.0")  
view(pwt8.0)
```




```
br <- subset(pwt8.0, country=="Brazil",  
             select = c("rgdpna", "emp", "xr"))
```

```
colnames(br) <- c("PIB", "Emprego", "Câmbio")
```

```

PIB <- br$PIB[45:62]
EMPREGO <- br$Emprego[45:62]
CAMBIO <- br$Câmbio[45:62]
Anos <- seq(from=1994, to=2011, by=1)


```




```
plot(EMPREGO, type = "l")
emprego <- ts(EMPREGO, start = 1994, frequency = 1)
plot(emprego, main="Pessoa Empregadas no Brasil",
      ylab="Qte de Pessoas Empregadas-milhões",
      xlab="Ano")
```

```
acf(emprego)
pacf(emprego)
```

Series emprego



Series emprego



```
reglinEMP <- lm(EMPREGO ~ Anos)
reglinEMP
plot(emprego)
abline(reglinEMP, col="Blue")

summary(reglinEMP)
```

Call:  
lm(formula = EMPREGO ~ Anos)


Residuals:

Min	1Q	Median	3Q	Max
-3.3808	-1.3820	0.0899	1.0826	4.6436


Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	-3.737e+03	1.958e+02	-19.08	1.97e-12	***
Anos	1.908e+00	9.778e-02	19.51	1.40e-12	***

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1




```
residuoEMP <- reglinEMP$residuals  
reglinEMPres <- lm(residuoEMP ~ Anos)  
plot(residuoEMP,type="l")  
abline(reglinEMPres, col="Blue")
```





```
pdemprego <- diff(EMPREGO)
diferenca1 <- (data.frame(EMPREGO[2:18],pdemprego))
DIFERENCA <- ts(diferenca1, start = 1994, frequency = 1)
plot(DIFERENCA, plot.type="single", col=c("Black","Green"))
```



```
pdemprego1 <- diff(emprego)
TesteDF_Emprego1_trend <- ur.df(pdemprego1, "trend", lags = 1)
summary(TesteDF_Emprego1_trend)
```

```
pdemprego2 <- diff(diff(emprego))
TesteDF_Emprego2_trend <- ur.df(pdemprego2, "trend", lags = 1)
summary(TesteDF_Emprego2_trend)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

```
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-1.5029 -0.8663 -0.0643  0.4765  2.5857
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.32512    0.79632   1.664   0.1243
z.lag.1      -0.82873    0.38961  -2.127   0.0569 .
tt           0.04494    0.09784   0.459   0.6549
z.diff.lag   -0.30943    0.24691  -1.253   0.2361
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 1.318 on 11 degrees of freedom
Multiple R-squared:  0.7223,    Adjusted R-squared:  0.6466
F-statistic: 9.538 on 3 and 11 DF,  p-value: 0.002147
```

value of test-statistic is: -2.1271 2.1918 2.7568

```
Critical values for test statistics:
      1pct  5pct 10pct
tau3  -4.38 -3.60 -3.24
phi2   8.21  5.68  4.67
phi3  10.61  7.24  5.91
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

```
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-1.963 -1.103  0.172  1.003  2.498
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.5612    1.0479   1.490   0.16711
z.lag.1      -2.2447    0.5709  -3.932   0.00281 **
tt           -0.1320    0.1090  -1.211   0.25391
z.diff.lag    0.2699    0.2993   0.902   0.38837
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 1.559 on 10 degrees of freedom
Multiple R-squared:  0.8941,    Adjusted R-squared:  0.8624
F-statistic: 28.15 on 3 and 10 DF,  p-value: 3.438e-05
```

value of test-statistic is: -3.9318 5.1638 7.7303

```
Critical values for test statistics:
      1pct  5pct 10pct
tau3  -4.38 -3.60 -3.24
phi2   8.21  5.68  4.67
phi3  10.61  7.24  5.91
```

```
#Estimando a série temporal
```

```
arima123 <- arima(emprego, c(1,2,3))
```

```
#ARMA
```

```
arima120 <- arima(emprego, c(1,2,0))
```

```
arima121 <- arima(emprego, c(1,2,1))
```

```
arima122 <- arima(emprego, c(1,2,2))
```

```
arima220
```

```
arima221
```

```
arima222
```

```
arima223
```

```
#MA
```

```
arima021
```

```
arima022
```

```
arima023
```

```
#AR
```

```
arima0120
```

---